

Business Intelligence para a Análise de Incêndios Florestais

Hugo Guimarães^[8220337], Nuno Silva^[8180393], Diogo Pereira^[8200594], and Duarte Sampaio^[8190553]

Escola Superior de Tecnologia e Gestão
<https://www.estg.ipp.pt/>

Resumo Este trabalho apresenta o desenvolvimento de um sistema de Business Intelligence para análise de incêndios florestais em Portugal Continental (2020-2025). O projeto assenta na construção de um Data Warehouse dimensional que integra dados do ICNF, informação meteorológica (Open-Meteo) e índices de vegetação NDVI (MODIS). O processo ETL desenvolvido garante a extração, transformação e integração das diversas fontes de dados. A modelação dimensional segue a metodologia de Kimball, identificando três processos de negócio principais: Ocorrência de Incêndio, Meteorologia Diária e Monitorização de Vegetação. O sistema permite análises sobre áreas de risco, sazonalidade, impacto meteorológico e a influência do estado da vegetação na severidade das ocorrências. A visualização é realizada através de dashboards interativos em Microsoft Power BI, proporcionando uma ferramenta de apoio à decisão para a monitorização e prevenção de incêndios florestais.

Keywords: Data Warehouse · Business Intelligence · Incêndios Florestais · ETL · Modelação Dimensional · Power BI · NDVI · Portugal · Apoio à Decisão

1 Introdução

1.1 Contextualização

Os incêndios florestais representam, recorrentemente, uma das maiores calamidades naturais em Portugal, com uma incidência superior à média europeia [2]. Este fenómeno provoca, anualmente, graves prejuízos económicos, danos ambientais irreversíveis e impactos sociais profundos, incluindo a perda de vidas humanas e a destruição de bens [3].

A complexidade do combate e prevenção dos incêndios exige uma gestão baseada em dados concretos e fiáveis. Contudo, a informação relevante para o estudo destes eventos encontra-se frequentemente dispersa por diversas entidades e em formatos heterogêneos, dificultando uma visão integrada do problema [1]. A fragmentação dos dados estatísticos do setor florestal é reconhecida como um entrave à definição de políticas públicas eficazes e à alocação eficiente de recursos [4].

Neste contexto, a aplicação de sistemas de *Business Intelligence* (BI) e técnicas de *Data Mining* surge como uma solução promissora. Estas ferramentas permitem consolidar grandes volumes de dados históricos, detetar padrões ocultos e apoiar a tomada de decisão estratégica e operacional [5]. Compreender a relação entre as ocorrências de incêndio, as condições meteorológicas e as características do território é essencial para transitar de uma abordagem reativa para uma gestão preventiva mais robusta.

1.2 Objetivos do Trabalho

O objetivo principal deste projeto é o desenvolvimento de um sistema de suporte à decisão (*Decision Support System*) focado na análise de incêndios florestais em Portugal Continental. O trabalho centra-se na construção de um *Data Warehouse* dimensional que integre múltiplas fontes de dados.

Os objetivos específicos incluem:

- Integrar dados operacionais do ICNF com registos meteorológicos e índices de vegetação, superando a dispersão de fontes identificada;
- Identificar as zonas geográficas e as épocas do ano com maior risco de ignição;
- Analisar a correlação entre variáveis climáticas (temperatura, humidade, vento) e a severidade das ocorrências (área ardida);
- Avaliar a influência do estado da vegetação (NDVI) e do uso do solo na propagação do fogo;
- Disponibilizar visualizações interativas que auxiliem as entidades competentes na monitorização e planeamento.

1.3 Estrutura do Relatório

O presente relatório encontra-se organizado em cinco secções principais. A Secção 2 apresenta a caracterização das fontes de dados, a metodologia de modelação

dimensional adotada e a análise de perfil (*Data Profiling*). A Secção 3 descreve a arquitetura técnica e a implementação dos processos de Extração, Transformação e Carga (ETL). A Secção 4 apresenta os resultados obtidos através da análise dos indicadores de desempenho nos dashboards desenvolvidos em *Microsoft Power BI*. Por fim, a Secção 5 apresenta as conclusões e aponta caminhos para trabalhos futuros.

2 Dados e Metodologia

2.1 Caracterização das Fontes de Dados

A construção do Data Warehouse baseou-se na integração de múltiplas fontes de dados heterogêneas, com o objetivo de cruzar a informação operacional dos incêndios com variáveis meteorológicas, dados de observação terrestre e cobertura mediática.

Registo de Ocorrências (ICNF) A fonte primária de dados consistiu numa versão tratada dos registos do repositório `icnf_fire_data`¹, que agrega o histórico de ocorrências do serviço `fogos.icnf.pt`. Embora a fonte disponibilize registos desde 2001, este estudo incidiu sobre o período compreendido entre 2020 e 2025. Para garantir a relevância analítica, o *dataset* foi submetido a um processo de filtragem rigoroso, resultando na exclusão de:

- Registos com inconsistências geográficas (coordenadas em falta);
- Ocorrências com área ardida residual (inferior a 0,1 hectares);
- Registos incompletos, sem data de início ou fim de ocorrência.

Dados Meteorológicos Para caracterizar o contexto atmosférico de cada ocorrência, recorreu-se à API do serviço *Open-Meteo*². Através de um processo automatizado de extração, foram recolhidos dados históricos diários correspondentes às coordenadas geográficas e aos dias de atividade de cada incêndio, permitindo associar variáveis como temperatura, velocidade do vento e precipitação a cada evento específico.

Contexto Mediático (Google News) Para avaliar o impacto mediático dos incêndios, foram recolhidos artigos noticiosos através de *feeds* RSS do Google News. A extração foi filtrada por idioma (português) e por termos-chave associados a incêndios florestais no período em análise. Estes dados não estruturados foram processados para extração de metadados (título, fonte, data), visando complementar a análise da atenção pública dada às ocorrências mais severas.

Índices de Vegetação (MODIS) A monitorização do estado da vegetação foi realizada através do produto MOD13Q1 (NDVI de 16 dias com resolução de 250m), acedido via Google Earth Engine. Para cada perímetro de incêndio, foram calculadas estatísticas zonais (média e contagem de pixels) referentes aos períodos pré e pós-incêndio. Esta abordagem permitiu avaliar a biomassa disponível antes da ignição e quantificar o impacto na vegetação após a extinção.

¹ https://github.com/cityxdev/icnf_fire_data

² <https://open-meteo.com/>

2.2 Abordagem Metodológica

O desenho da arquitetura do sistema seguiu a metodologia de modelação dimensional orientada aos processos de negócio, proposta por Ralph Kimball. Esta abordagem permitiu identificar os processos fundamentais, definindo para cada um o grão (nível de detalhe), as dimensões (contexto analítico) e as medidas (factos numéricos).

Com base nos requisitos levantados, foram modelados quatro processos de negócio distintos, conforme descrito abaixo.

Ocorrência de Incêndio Este processo centraliza a informação relativa aos eventos de fogo, conforme ilustrado no modelo dimensional da Figura 1.

- **Grão:** Um registo por incêndio, identificado univocamente pelo `incident_id`.
- **Dimensões:** Tempo (início/fim), Localização (Distrito, Concelho, Freguesia), Tipo de Incêndio e possível causa.
- **Medidas:** Área ardida (ha), duração (horas) e métricas derivadas (ex: taxa de expansão).




Figura 1. Modelo em estrela para o processo de Ocorrência de Incêndio

Meteorologia Diária O modelo apresentado na Figura 2 permite a análise das condições ambientais que propiciam ou agravam as ocorrências.

- **Grão:** Registo diário das condições meteorológicas num determinado local geográfico afetado.
- **Dimensões:** Tempo (Dia) e Localização (coordenadas aproximadas ou freguesia).
- **Medidas:** Temperatura (média e máxima), humidade relativa, velocidade do vento e precipitação acumulada.




Figura 2. Modelo em estrela para o processo de Meteorologia

Monitorização de Vegetação Este processo avalia o impacto ecológico e o estado do combustível florestal (Figura 3).

- **Grão:** Medições de índices de vegetação agregadas por perímetro de incêndio e janela temporal.

- **Dimensões:** Tempo (Janela pré/pós incêndio), Localização.
- **Medidas:** NDVI médio pré-incêndio (combustível disponível), NDVI médio pós-incêndio e variação percentual (severidade do dano).




Figura 3. Modelo em estrela para o processo de Vegetação

Cobertura Mediática A Figura 4 ilustra a estrutura que suporta a análise da repercussão pública e do impacto mediático dos eventos.

- **Grão:** Um artigo noticioso individual, identificado univocamente por um id.
- **Dimensões:** Tempo (Data de publicação), Fonte (Entidade emissora/Jornal) e Sentimento (Classificação da tonalidade da notícia).
- **Medidas:** *Risk Score* (pontuação de risco associada), Polaridade (valor numérico do sentimento) e volume de notícias (contagem).

2.3 Perfil dos Dados (Data Profiling)

O *Data Profiling* constitui uma etapa fundamental na análise exploratória, permitindo aferir a estrutura, qualidade e integridade dos dados antes da sua integração no *Data Warehouse*. Esta secção detalha a análise efetuada sobre o conjunto de dados principal, proveniente do Instituto da Conservação da Natureza e das Florestas (ICNF).

A análise incidiu sobre 23 variáveis selecionadas pela sua relevância para os objetivos do projeto, abrangendo dimensões geográficas, temporais, métricas de severidade e contexto meteorológico. Dado que as restantes fontes de dados (ex:




Figura 4. Modelo em estrela para o processo de Cobertura Mediática

Open-Meteo) foram integradas por derivação espacial e temporal a partir deste *dataset* base, a validação da qualidade dos dados do ICNF assume um papel central na fiabilidade do sistema.

Análise de Completude A verificação de valores nulos evidenciou padrões distintos de preenchimento. Destaca-se a elevada taxa de ausência nas variáveis meteorológicas originais, reflexo de limitações na cobertura histórica da rede de estações ou falhas no registo sistemático.

A ausência de dados em cerca de 30% dos registos climáticos (Tabela 1) reforçou a decisão de ignorar estes campos em favor da integração com a API do *Open-Meteo*. Esta abordagem garante não só a completude total das variáveis climáticas, como também o acesso a um leque mais alargado de indicadores atmosféricos.

Por outro lado, as variáveis categóricas de classificação (TIPO, CAUSA, TIPOCAUSA) apresentam uma elevada completude (superior a 93%). Contudo, apesar da baixa incidência de nulos nas variáveis da família "Causa" e nos índices de perigo (FFMC e FWI), optou-se por isolar os registos incompletos em tabelas de quarentena. Esta estratégia permite uma validação posterior sem comprometer a carga dos dados válidos, salvaguardando variáveis cruciais para a análise de risco.

Unicidade e Duplicados A integridade referencial e a unicidade dos registos são pré-requisitos essenciais para evitar a distorção de medidas agregadas no *Data Warehouse*.

A análise confirmou a inexistência de identificadores (*IDs*) duplicados ou de registos inteiramente redundantes. Este resultado valida a qualidade dos dados de origem, dispensando, deste modo, etapas complexas de deduplicação durante o processo de ETL e garantindo que cada ocorrência de incêndio é contabilizada uma única vez nas análises estatísticas.

Tabela 1. Análise de valores nulos por variável

Variável	Nulos (%)	Nulos (Qtd)	Total Registos
TEMPERATURA	29.9	732	2451
HUMIDADERELATIVA	29.9	732	2451
CAUSA	7.5	184	2451
TIPOCAUSA	7.5	184	2451
CAUSAFAMILIA	7.5	184	2451
FFMC	0.2	6	2451
FWI	0.2	6	2451

Deteção de Outliers A análise de distribuição, representada pelos boxplots na Figura 5, permitiu identificar o comportamento das variáveis numéricas:

- **Área Ardida:** As variáveis de área (Total, Mato, Povoamento) exibem uma forte assimetria positiva. A concentração de dados em valores baixos, acompanhada por uma longa cauda de *outliers* superiores, é característica do fenómeno dos incêndios florestais: eventos raros, mas de dimensão catastrófica. Estes valores extremos representam ocorrências reais e devem ser preservados.
- **Meteorologia:** A Temperatura segue uma distribuição tendencialmente simétrica, enquanto a Humidade Relativa apresenta *outliers* inferiores consistentes com períodos de seca extrema.
- **Índices de Perigo:** O FFMC e o FWI apresentam *outliers* superiores que sinalizam condições excepcionais de perigo de incêndio, validando a sua utilidade como indicadores de alerta.

Distribuição Espacial e Consistência A análise geográfica (Figura 6) evidencia uma forte concentração de ocorrências nos distritos do interior Norte e Centro. Esta assimetria reflete a interação entre coberto florestal, relevo regional e fatores socioeconómicos.

Ao nível da freguesia (Figura 7), identificam-se *hotspots* locais onde a recorrência é crítica. É importante destacar que as freguesias com maior frequência de ignições não correspondem necessariamente às áreas de maior área ardida, sugerindo dinâmicas distintas entre a ocorrência e a propagação do fogo.

Relativamente à qualidade dos dados categóricos, salienta-se que a geração destes gráficos não exigiu qualquer normalização prévia de texto. A ausência de categorias duplicadas por erros de sintaxe (ex: "Aveiro"vs "aveiro ") demonstra a consistência das dimensões geográficas na fonte, simplificando a criação de tabelas de dimensão.

Análise Causal e Correlações A matriz de correlações (Figura 8) permitiu validar relações esperadas e identificar variáveis redundantes para a modelação dimensional.

Da análise destacam-se as seguintes relações lineares:




Figura 5. Boxplots das variáveis numéricas do ICNF




Figura 6. Os 20 distritos com maior frequência de ocorrências




Figura 7. As 20 freguesias com maior frequência de ocorrências




Figura 8. Matriz de correlações (Pearson) entre variáveis numéricas

- **Composição da Área Ardida:** Correlações fortes ($r > 0.7$) entre a Área Total e as suas componentes (Mato/Povoamento), indicando a predominância do tipo de vegetação afetado.
- **Fatores Meteorológicos:** A correlação negativa entre Temperatura e Humidade Relativa, bem como a forte correlação entre os índices FFMC e FWI, validam a consistência física dos dados.
- **Severidade vs. Clima:** As correlações moderadas entre índices meteorológicos e área ardida sugerem que, embora o clima propicie as condições para grandes incêndios, a dimensão final da ocorrência depende de outros fatores operacionais (meios de combate, acessibilidades), justificando a inclusão destas variáveis no modelo multidimensional.

3 Arquitetura e Implementação ETL

3.1 Arquitetura ETL/DSA

A arquitetura implementada para o sistema de suporte analítico fundamenta-se num processo de integração que reúne dados provenientes de fontes heterogêneas, aplica as transformações necessárias e prepara a sua posterior carga no repositório analítico. Esta secção apresenta uma visão geral do fluxo de dados e dos componentes envolvidos, permitindo compreender a organização da informação antes da sua disponibilização no *Data Warehouse*.

A Figura 9 ilustra a arquitetura do processo ETL desenhado para o sistema. À esquerda da figura, identificam-se as fontes de dados, que incluem os ficheiros disponibilizados pelo ICNF, dados meteorológicos em formato bruto e informação externa, como a cobertura mediática. O fluxo de dados prossegue para a área de preparação (*Staging Area*), onde ocorre o processamento central. Esta camada engloba estruturas de suporte, um espaço de quarentena para validação de qualidade e a lógica de transformação que organiza os dados em zonas específicas. Por fim, após a devida preparação e limpeza, a informação é encaminhada para a área de carregamento, sendo persistentemente armazenada no *Data Warehouse*.




Figura 9. Arquitetura ETL (Estrutura da DSA)

3.2 Processos de Negócio e Modelação Dimensional

A modelação do processo ETL é complementada pela criação de diagramas BPMN que permitem representar de forma clara e sistemática o fluxo de atividades envolvidas na preparação dos dados que irão alimentar o *Data Warehouse*. Estes diagramas facilitam a compreensão das várias fases do processo, permitindo identificar dependências e contribuir para a deteção de possíveis pontos de melhoria na execução das tarefas.

Existem três níveis de diagramas BPMN que representam a aplicação do processo ETL: nível do processo, nível padrão e nível da tarefa. No âmbito deste projeto, não foi necessária a especificação dos diagramas ao nível da tarefa, nem a descrição individual de todos os processos ao nível padrão, dada a similaridade estrutural entre eles.

3.3 Visão Global do Processo

A Figura 10 ilustra a arquitetura macroscópica do fluxo ETL, modelada através de um diagrama BPMN ao nível do processo. Esta representação de alto nível oferece uma visão abrangente das etapas fundamentais, desde o carregamento das tabelas de dimensão até ao povoamento das tabelas de factos do *Data Warehouse*.




Figura 10. Diagrama BPMN ao nível do processo

3.4 Detalhe de Atividades Específicas

Algumas partes do processo ETL são representadas por diagramas BPMN ao nível padrão. Estes diagramas permitem aprofundar tarefas que exigem uma

descrição mais granular, como procedimentos de validação, mecanismos de controlo de qualidade ou etapas específicas de transformação e enriquecimento dos dados.

Abaixo, detalham-se os fluxos específicos para o carregamento das principais dimensões e da tabela de factos central.

Carregamento da Dimensão Tipo de Incêndio Este processo (Figura 11) foca-se na classificação das ocorrências. O fluxo garante a normalização das categorias de incêndio (ex: Agrícola, Florestal, Queimada) e a gestão de novos tipos que possam surgir nos dados de origem, assegurando a consistência na categorização das ocorrências.




Figura 11. Diagrama BPMN nível padrão para a dimensão Tipo de Incêndio

Carregamento da Dimensão Tempo (Dia) A dimensão temporal é crítica para a análise de sazonalidade. O processo ilustrado na Figura 12 é responsável por gerar e validar os registos diários, permitindo a posterior agregação de factos por dia, mês, ano ou estação.

Carregamento da Dimensão Localização Dado o carácter geográfico do projeto, o carregamento da dimensão de localização exige o tratamento cuidadoso da hierarquia espacial. O fluxo ilustrado na Figura 13 assegura a extração e carregamento das localizações únicas (Distrito, Concelho e Freguesia), garantindo que cada área administrativa possui um identificador único no sistema antes de ser associada a uma ocorrência.




Figura 12. Diagrama BPMN nível padrão para a dimensão Dia




Figura 13. Diagrama BPMN nível padrão para a dimensão de Localização

Carregamento da Tabela de Factos de Incêndio Este é o processo central do sistema, onde as métricas (como a área ardida e a duração) são integradas com as chaves das dimensões anteriormente carregadas. O diagrama da Figura 14 demonstra a lógica de obtenção das chaves substitutas (*surrogate keys*) e o cálculo de medidas derivadas antes da inserção final no *Data Warehouse*.




Figura 14. Diagrama BPMN nível padrão para a tabela de factos de Incêndio

3.5 Implementação dos Processos de ETL

O presente capítulo detalha a arquitetura e o desenvolvimento dos processos de ETL (*Extract, Transform, Load*). Para a orquestração e execução dos fluxos de dados, recorreu-se à plataforma Microsoft SQL Server Integration Services (SSIS). O objetivo central desta etapa foi garantir a integridade, limpeza e estruturação dos dados provenientes de fontes heterogêneas antes do seu carregamento no Data Warehouse. Esta secção explora as especificidades de implementação para cada conjunto de dados temático.

Transversalmente a todos os processos, optou-se por uma estratégia de gestão de erros baseada em registos de texto. Caso ocorram falhas na inserção de dados na *Staging Area* (devido a incompatibilidades de formato ou tipo de dados), os registos rejeitados são desviados para ficheiros de *log* para posterior auditoria, em detrimento de tabelas de quarentena na base de dados, evitando que erros estruturais graves bloqueiem o fluxo de carga.

3.6 Incêndios

Para operacionalizar o processo de ETL referente aos dados do ICNF, desenvolveu-se um executável a partir do *script* de extração, criando-se posteriormente outro responsável pela inserção dos dados na *Staging Area*. Esta abordagem mista foi adotada dado que o SSIS pode apresentar limitações na manipulação complexa de ficheiros CSV; assim, optou-se por realizar o pré-processamento e limpeza inicial em *Python* para garantir maior flexibilidade e simplicidade no fluxo.

Já com os dados na *Staging Area*, são aplicados filtros através de *scripts* em T-SQL com o objetivo de remover registos com valores nulos de latitude e longitude, bem como excluir incêndios cuja área ardida não seja significativa (igual ou inferior a 0,1 hectares).

Após a filtragem, as tabelas de dimensão e factos no Data Warehouse são criadas e carregadas com os dados processados provenientes da tabela de *Staging*.




Figura 15. Processo ETL para incêndios

3.7 Temperaturas

No fluxo de ETL dos dados meteorológicos, o SSIS inicia a execução chamando um *script* em *Python* (via executável). Este *script* consulta a tabela de factos dos incêndios para identificar os dias e locais exatos das ocorrências, extraindo apenas a meteorologia relevante e inserindo-a na *Staging Area*.

Uma vez carregados os dados em *Staging*, procede-se ao povoamento das dimensões e da tabela de factos no *Data Warehouse*. Visto que os dados meteorológicos são recolhidos de forma direcionada (apenas para os dias/loais necessários) e provêm diretamente da API do *Open-Meteo*, não é necessária a aplicação de filtros adicionais nesta fase.

Dado que este processo depende dos dados de localização e data dos fogos, a sua execução tem como precedência obrigatória a conclusão do processo ETL descrito na secção 3.6.

3.8 Cobertura Mediática

Neste fluxo, o executável responsável pela extração de notícias não foi integrado diretamente no pacote ETL principal. Isto deve-se ao facto de o processo incluir,




Figura 16. Processo ETL para temperaturas

para além da extração, uma etapa de enriquecimento de dados através de um modelo de *Machine Learning*. Visto que esta etapa requer um tempo de processamento elevado, optou-se por desacoplá-la para simplificar a demonstração do processo de carga.

Portanto, para o correto funcionamento deste processo no SSIS, é pré-requisito a existência de um ficheiro JSON no diretório configurado, contendo os dados já processados pelo modelo. A partir desse ficheiro, o SSIS aciona um executável auxiliar para inserir os dados na *Staging Area*. Com os dados carregados, o fluxo prossegue para alimentar todas as tabelas do respetivo esquema em estrela através de *scripts* em T-SQL.




Figura 17. Processo ETL para cobertura mediática

3.9 Vegetação

À semelhança do verificado na cobertura mediática, a extração de dados do *Google Earth Engine* (GEE) não foi integrada no fluxo automatizado do SSIS, devido à complexidade técnica de automatização da recolha nesta plataforma específica. Desta forma, o projeto SSIS foi configurado para ingerir ficheiros CSV previamente extraídos e depositados no diretório do projeto.

Foi estabelecida uma dependência funcional estrita para este processo: a sua execução ocorre obrigatoriamente após o processo ETL dos Incêndios. Esta precedência é necessária pois o carregamento dos dados de vegetação exige a consulta prévia à tabela de factos dos incêndios, garantindo assim a correta associação com a dimensão de localização e a integridade referencial do modelo.

Tal como nos restantes processos, eventuais falhas de inserção de registos resultam na geração de um ficheiro de *log* de erros.




Figura 18. Processo ETL para vegetação

4 Resultados e Discussão

5 Conclusões e Trabalho Futuro

O presente trabalho alcançou o objetivo principal de desenvolver um sistema de *Business Intelligence* focado na análise de incêndios florestais em Portugal Continental. A dispersão de dados, identificada inicialmente como um desafio central, foi mitigada através da implementação de um processo ETL robusto, capaz de centralizar informação de natureza heterogênea. A integração de dados operacionais do ICNF com fontes externas, nomeadamente a meteorologia (*Open-Meteo*) e índices de vegetação, permitiu enriquecer o contexto analítico, oferecendo novas perspetivas sobre as ocorrências.

A adoção da metodologia de modelação dimensional de Kimball provou ser eficaz, facilitando a estruturação do *Data Warehouse* e garantindo um desempenho adequado nas consultas. A definição clara dos processos de negócio (Ocorrência, Meteorologia, cobertura mediática, e Vegetação) permitiu criar um modelo intuitivo e alinhado com as necessidades de análise.

A etapa de *Data Profiling* revelou-se crítica para a fiabilidade do sistema. A identificação de lacunas nas variáveis meteorológicas originais validou a decisão estratégica de recorrer a APIs externas, assegurando a completude da informação climática. Adicionalmente, a componente geográfica permitiu identificar padrões de concentração espacial (*hotspots*), validando a utilidade do sistema para o planeamento estratégico e prevenção.

Em suma, a solução desenvolvida transforma dados brutos e dispersos em conhecimento acionável, oferecendo às entidades competentes uma ferramenta de apoio à decisão baseada em evidências históricas.

5.1 Limitações do Estudo

Apesar dos resultados positivos, o projeto apresenta limitações que devem ser consideradas. A primeira reside na componente de cobertura mediática. Embora os dados tenham sido extraídos, a sua integração plena no modelo de análise carece ainda de técnicas avançadas de processamento de linguagem natural (*NLP*) para aferir o sentimento e a relevância das notícias.

Uma segunda limitação prende-se com a escassez de informação recolhida sobre a vegetação antes e depois de cada incêndio, o que condiciona uma avaliação mais profunda do impacto ecológico e da recuperação dos solos.

Por fim, o período temporal analisado (2020-2025), embora recente e relevante, é relativamente curto para a identificação de tendências climáticas de longo prazo.

5.2 Trabalho Futuro

Para dar continuidade a este projeto e potenciar a sua utilidade, sugerem-se as seguintes linhas de investigação e desenvolvimento:

- **Automatização integral do ETL:** Desenvolver mecanismos de extração automática para as fontes de Cobertura Mediática e Vegetação, eliminando

- a intervenção manual atualmente necessária e alinhando estes processos com a automação já existente para os dados do ICNF e Meteorologia;
- **Integração de Dados Operacionais (DECIR):** Implementar rotinas de extração de texto (*OCR/Text Mining*) para processar os relatórios da Diretiva Operacional Nacional. Isto permitiria incorporar dados sobre meios aéreos e terrestres, possibilitando a criação de métricas sobre a eficácia do combate e tempos de resposta;
 - **Análise de Sentimento (NLP):** Implementar algoritmos de processamento de linguagem natural para classificar automaticamente as notícias (positiva/negativa/neutra), permitindo correlacionar o impacto mediático com a severidade dos incêndios;
 - **Integração em Tempo Real:** Adaptar a arquitetura para processamento em *near real-time*, permitindo o acompanhamento de ocorrências ativas nos *dashboards* de controlo;
 - **Enriquecimento de Dados:** Incorporar dados sobre a orografia do terreno (declive e exposição solar), fatores determinantes na modelação da velocidade e direção de propagação das chamas.

Referências

1. Almeida, J., Costa, M.: Desafios na integração de dados para a gestão dos incêndios florestais em Portugal. *Revista de Gestão do Território e Floresta* **5**(2), 45–62 (2023), discussão da dispersão de dados entre diferentes entidades e formatos heterogêneos
2. Autor, A., Pereira, P.: Incêndios florestais em Portugal: dinâmicas, impactos e políticas. In: *Incêndios Florestais em Portugal: dinâmicas e políticas*, pp. 15–48. Editora Acadêmica, Lisboa (2016), análise dos impactos ambientais, económicos e sociais dos incêndios florestais em Portugal continental
3. para a Gestão Integrada de Fogos Rurais, A.: Relatório anual sobre incêndios rurais em Portugal. Relatório técnico (2024), estatísticas nacionais de ocorrências, área ardida, prejuízos económicos e vítimas
4. Oliveira, R., Santos, L.: Fragmentação estatística no setor florestal português: implicações para as políticas públicas. *Revista de Estudos Rurais e Florestais* **12**(1), 73–90 (2018), análise crítica da falta de integração de informação e dos seus efeitos na definição de políticas
5. Silva, T., Rodrigues, P., Carvalho, F.: Aplicação de business intelligence e data mining à gestão de incêndios florestais em Portugal. In: *Atas da Conferência Portuguesa de Sistemas de Informação Geográfica e Florestal*. pp. 201–214. Coimbra (2023), proposta de sistema de BI para integração de dados históricos, meteorológicos e territoriais