

Business Intelligence para a Análise de Incêndios Florestais

Hugo Guimarães^[8220337], Nuno Silva^[8180393], Diogo Pereira^[8200594], and Duarte Sampaio^[8190553]

Escola Superior de Tecnologia e Gestão
<https://www.estg.ipp.pt/>

Resumo Este trabalho apresenta o desenvolvimento de um sistema de Business Intelligence para análise de incêndios florestais em Portugal Continental (2020-2025). O projeto assenta na construção de um Data Warehouse dimensional que integra dados do ICNF, informação meteorológica (Open-Meteo), índices de vegetação NDVI (MODIS), cobertura do solo (CORINE Land Cover), e indicadores socioeconómicos (INE). O processo ETL desenvolvido garante a extração, transformação e integração das diversas fontes de dados. A modelação dimensional segue a metodologia de Kimball, identificando quatro processos de negócio: Ocorrência de Incêndio, Meteorologia Diária, Operações de Combate e Monitorização de Vegetação. O sistema permite análises sobre áreas de risco, sazonalidade, impacto meteorológico, influência da vegetação, eficácia dos meios de combate e impacto socioeconómico. A visualização é realizada através de dashboards interativos em Microsoft Power BI, proporcionando uma ferramenta de apoio à decisão para entidades responsáveis pela prevenção e combate a incêndios florestais.

Keywords: Data Warehouse · Business Intelligence · Incêndios Florestais · ETL · Modelação Dimensional · Power BI · NDVI · Portugal · Apoio à Decisão

1 Introdução

1.1 Contextualização

1.2 Objetivos do Trabalho

1.3 Estrutura do Artigo

2 Dados e Metodologia

2.1 Caraterização das Fontes de Dados

A construção do Data Warehouse assentou na integração de múltiplas fontes de dados heterogêneas, permitindo fundir informação operacional de incêndios com variáveis meteorológicas, dados de observação terrestre e cobertura mediática.

Registo de Ocorrências (ICNF) A principal fonte de dados consistiu numa versão tratada dos registos do repositório `icnf_fire_data`¹, que agrega o histórico de ocorrências do serviço `fogos.icnf.pt`. Embora na fonte conste dados desde o ano de 2001, no estudo realizado utilizou-se dados desde o período entre 2020 e 2025. Para garantir a relevância analítica, o dataset foi submetido a um processo de filtragem, resultando na exclusão de:

- Registos com inconsistências geográficas (coordenadas em falta);
- Ocorrências com área ardida residual (inferior a 0,1 hectares);
- Registos incompletos sem data de início ou fim

Dados Meteorológicos Para caracterizar o contexto atmosférico de cada ocorrência, recorreu-se à API do serviço *Open-Meteo*². Onde, através de um processo automatizado de extração, foram recolhidos dados históricos diários correspondentes às coordenadas geográficas e aos dias de atividade de cada incêndio, permitindo associar variáveis como temperatura, vento e precipitação a cada evento.

Contexto Mediático (Google News) Para avaliar o impacto mediático dos incêndios, foram recolhidos artigos noticiosos através de feeds RSS do Google News. A extração foi filtrada por idioma (português) e por termos-chave associados a incêndios florestais no período de 2020 a 2025. Estes dados não estruturados foram processados para extração de metadados (título, fonte, data), visando complementar a da atenção pública dada às ocorrências.

Índices de Vegetação (MODIS) A monitorização do estado da vegetação foi realizada através do produto MOD13Q1 (NDVI de 16 dias com resolução de 250m), acedido via Google Earth Engine. Para cada perímetro de incêndio, foram calculadas estatísticas zonais (média e contagem de píxeis) referentes aos períodos pré e pós-incêndio (focando o intervalo 2020–2024), permitindo avaliar a biomassa disponível antes da ignição e o impacto na vegetação após a extinção.

¹ https://github.com/cityxdev/icnf_fire_data

² <https://open-meteo.com/>

Ocupação do Solo (CORINE) Para a caracterização do território, utilizou-se o inventário *CORINE Land Cover* (CLC 2018). Esta fonte permitiu atribuir classes padronizadas de uso do solo aos perímetros arditos, possibilitando a análise da suscetibilidade ao fogo em diferentes tipos de coberto (floresta, mato, agrícola ou urbano).

2.2 Abordagem Metodológica

O desenho da arquitetura do sistema seguiu a metodologia de modelação dimensional orientada aos processos de negócio, proposta por Ralph Kimball. Esta abordagem permitiu identificar os processos fundamentais da organização, definindo para cada um o grão (nível de detalhe), as dimensões (contexto) e as medidas (factos numéricos).

Com base nos requisitos levantados, foram modelados quatro processos de negócio distintos, conforme descrito abaixo.

Ocorrência de Incêndio Este processo centraliza a informação sobre os eventos de fogo.

- **Grão:** Um registo por incêndio, identificado univocamente pelo `incident_id`.
- **Dimensões:** Tempo (data/hora início e fim), Localização (distrito, concelho, freguesia), Tipo de Incêndio e Entidade Responsável.
- **Medidas:** Área ardida (ha), duração (horas) e métricas derivadas como a taxa de expansão.

Meteorologia Diária Permite a análise das condições ambientais adversas.

- **Grão:** Registo diário das condições meteorológicas num determinado local geográfico afetado.
- **Medidas:** Temperatura (média e máxima), humidade relativa, velocidade do vento e precipitação.

Operações de Combate Foca-se na resposta operacional e logística.

- **Grão:** Cada registo corresponde a uma intervenção ou mobilização de meios para um incêndio específico.
- **Medidas:** Número de operacionais, veículos terrestres, meios aéreos, tempo de resposta e eficácia da contenção.

Monitorização de Vegetação Avalia o impacto ecológico e o estado do combustível.

- **Grão:** Medições de índices de vegetação (NDVI) agregadas por perímetro de incêndio e janela temporal.
- **Medidas:** NDVI médio pré-incêndio (combustível disponível) e pós-incêndio (severidade do dano).

2.3 Perfil dos Dados (Data Profiling)

O *Data Profiling* constitui uma etapa fundamental na análise exploratória, permitindo comparar a estrutura, qualidade e integridade dos dados antes da integração no Data Warehouse. Esta secção detalha a análise efetuada sobre o conjunto de dados principal, proveniente do Instituto da Conservação da Natureza e das Florestas (ICNF).

A análise incidiu sobre 23 variáveis selecionadas pela sua relevância para os objetivos do projeto, abrangendo dimensões geográficas, temporais, métricas de severidade e contexto meteorológico. Dado que as restantes fontes de dados (ex: Open-Meteo) foram integradas por derivação espacial e temporal a partir deste dataset base, a validação da qualidade dos dados do ICNF assume um papel central na fiabilidade do sistema.

Análise de Completude A verificação de valores nulos evidenciou padrões distintos de preenchimento. Destaca-se a elevada taxa de ausência nas variáveis meteorológicas originais, reflexo de limitações na cobertura histórica da rede de estações ou falhas no registo sistemático.

A ausência de dados em cerca de 30% dos registos climáticos (Tabela 1) reforçou a decisão de ignorar estes campos em favor da integração com a API do *Open-Meteo*. Esta abordagem garante não só a completude total das variáveis climáticas, como também o acesso a um leque mais alargado de indicadores atmosféricos.

Por outro lado, as variáveis categóricas de classificação (TIPO, CAUSA, TIPOCAUSA) apresentam uma elevada completude (superior a 93%). Contudo, apesar da baixa incidência de nulos nas variáveis da família "Causa" e nos índices de perigo (FFMC e FWI), optou-se por isolar os registos incompletos em tabelas de quarentena. Esta estratégia permite uma validação posterior sem comprometer a carga dos dados válidos, salvaguardando variáveis cruciais para a análise de risco.

Tabela 1. Análise de valores nulos por variável

Variável	Nulos (%)	Nulos (Qtd)	Total Registos
TEMPERATURA	29.9	732	2451
HUMIDADERELATIVA	29.9	732	2451
CAUSA	7.5	184	2451
TIPOCAUSA	7.5	184	2451
CAUSAFAMILIA	7.5	184	2451
FFMC	0.2	6	2451
FWI	0.2	6	2451

Unicidade e Duplicados A integridade referencial e a unicidade dos registos são pré-requisitos essenciais para evitar a distorção de medidas agregadas no Data Warehouse.

A análise confirmou a inexistência de identificadores (*IDs*) duplicados ou de registos inteiramente redundantes. Este resultado valida a qualidade dos dados de origem, assim, dispensando etapas complexas de deduplicação durante o processo de ETL e garantindo que cada ocorrência de incêndio é contabilizada uma única vez nas análises estatísticas.

Deteção de Outliers A análise de distribuição, representada pelos boxplots na Figura 1, permitiu identificar o comportamento das variáveis numéricas:




Figura 1. Boxplots das variáveis numéricas do ICNF

- **Área Ardida:** As variáveis de área (Total, Mato, Povoamento) exibem uma forte assimetria positiva. A concentração de dados em valores baixos, acompanhada por uma longa cauda de *outliers* superiores, é característica do fenómeno dos incêndios florestais: eventos raros, mas de dimensão catastrófica. Estes valores extremos representam ocorrências reais e devem ser preservados.
- **Meteorologia:** A Temperatura segue uma distribuição tendencialmente simétrica, enquanto a Humidade Relativa apresenta *outliers* inferiores consistentes com períodos de seca extrema.
- **Índices de Perigo:** O FFMCI e o FWI apresentam *outliers* superiores que sinalizam condições excepcionais de perigo de incêndio, validando a sua utilidade como indicadores de alerta.

Distribuição Espacial e Consistência A análise geográfica (Figura 2) evidencia uma forte concentração de ocorrências nos distritos do interior Norte e Centro. Esta assimetria reflete a interação entre coberto florestal, relevo regional e fatores socioeconómicos.




Figura 2. Os 20 distritos com maior frequência de ocorrências

Ao nível da freguesia (Figura 3), identificam-se *hotspots* locais onde a recorrência é crítica. É importante destacar que as freguesias com maior frequência de ignições não correspondem necessariamente às áreas de maior área ardida, sugerindo dinâmicas distintas entre a ocorrência e a propagação do fogo.

Relativamente à qualidade dos dados categóricos, salienta-se que a geração destes gráficos não exigiu qualquer normalização prévia de texto. A ausência de categorias duplicadas por erros de sintaxe (ex: "Aveiro" vs "aveiro ") demonstra a consistência das dimensões geográficas na fonte, simplificando a criação de tabelas de dimensão.




Figura 3. As 20 freguesias com maior frequência de ocorrências

Análise Causal e Correlações A matriz de correlações (Figura 4) permitiu validar relações esperadas e identificar variáveis redundantes para a modelação dimensional.

Da análise destacam-se as seguintes relações lineares:

1. **Composição da Área Ardida:** Correlações fortes ($r > 0.7$) entre a Área Total e as suas componentes (Mato/Povoamento), indicando a predominância do tipo de vegetação afetado.
2. **Fatores Meteorológicos:** A correlação negativa entre Temperatura e Humidade Relativa, bem como a forte correlação entre os índices FFMC e FWI, validam a consistência física dos dados.
3. **Severidade vs. Clima:** As correlações moderadas entre índices meteorológicos e área ardida sugerem que, embora o clima propicie as condições para grandes incêndios, a dimensão final da ocorrência depende de outros fatores operacionais (meios de combate, acessibilidades), justificando a inclusão destas variáveis no modelo multidimensional.




Figura 4. Matriz de correlações (Pearson) entre variáveis numéricas

3 Arquitetura e Implementação ETL

3.1 Arquitetura ETL/DSA

A arquitetura implementada para o sistema de suporte analítico assenta num processo de integração que reúne dados provenientes de diferentes fontes, aplica transformações adequadas e prepara a sua posterior carga no repositório analítico. Esta secção apresenta a visão geral do fluxo de dados e dos componentes envolvidos, permitindo compreender como a informação é organizada antes de ser disponibilizada no armazém de dados.

A Figura 5 representa a arquitetura do processo ELT utilizado no sistema analítico. No lado esquerdo encontram-se as fontes de dados. Estas incluem ficheiros fornecidos pelo ICNF, dados meteorológicos em formato bruto e informação proveniente da internet como a cobertura mediática. Os dados extraídos seguem para a área de preparação onde ocorre a transformação. Esta área inclui estruturas de suporte, um espaço de quarentena para validação e a camada de transformação que organiza os dados em zonas específicas de integração. Após a preparação, a informação é enviada para a área de carregamento onde é finalmente armazenada no data warehouse.




Figura 5. Arquitetura ELT (Estrutura da DSA)

3.2 Processos de Negócio e Modelação Dimensional

A modelação do processo ETL é complementada pela criação de diagramas BPMN que permitem representar de forma clara e sistemática o fluxo de atividades envolvidas na preparação dos dados que irão alimentar o data warehouse. Estes diagramas facilitam a compreensão das várias fases do processo, permitindo identificar dependências e contribuem para a deteção de possíveis pontos de melhoria na execução das tarefas.

Existem três níveis de diagramas BPMN que representam a aplicação do processo ETL, sendo eles: nível do processo; nível padrão e nível da tarefa. Sendo que, no âmbito deste projeto, não foi necessário a especificação dos diagramas ao nível da tarefa, como também não foram descritos de forma individual todos os processos ao nível padrão, visto que são todos bastante semelhantes entre si

3.3 Visão Global do Processo

Esta subsecção irá acolher o diagrama BPMN ao nível do processo. O objetivo deste nível é oferecer uma visão abrangente das principais etapas que compõem o fluxo do processo ETL, desde a obtenção das fontes de dados até ao carregamento final no data warehouse. A representação global permitirá compreender a articulação entre as atividades nucleares do sistema, bem como o percurso lógico seguido pelos dados ao longo de todo o ciclo de tratamento.

3.4 Detalhe de Atividades Específicas

Algumas partes do processo ETL serão representadas por diagramas BPMN ao nível padrão. Estes diagramas permitem aprofundar tarefas que exigem uma descrição mais granular, como procedimentos de validação, mecanismos de controlo de qualidade ou etapas específicas de transformação e enriquecimento dos dados provenientes das diferentes fontes.

3.5 Detalhes do ETL

O presente capítulo detalha a arquitetura e o desenvolvimento do processo de ETL (Extract, Transform, Load). Para a orquestração e execução dos fluxos de dados, recorreu-se à plataforma Microsoft SQL Server Integration Services (SSIS). O objetivo central desta etapa foi garantir a integridade, limpeza e estruturação dos dados provenientes de fontes heterogêneas antes de serem carregadas para o Data Warehouse. Esta secção explora as especificidades de implementação para cada conjunto de dados temático.

3.6 Incêndios

Para fazer o processo de ETL para os dados provenientes do ICNF, gerou-se um executável do script de extração dos dados do ICNF, e criou-se outro responsável por inserir os dados na Staging Area. Esta abordagem foi escolhida porque o SISS não apresenta mecanismos simples para a gestão de dados em formato CSV, portanto, por simplicidade, tanto neste processo como nos restantes, a manipulação dos dados, antes de serem carregados para a base de dados de staging, é realizada em python através de um executável.

Com os dados dentro da Staging Area, são realizados vários filtros através de scripts em T-SQL, para poder: remover valores nulos de latitude e longitude; e remover incêndios cuja zona queimada não seja significativa (superior a 0.1 hectares).




Figura 6. Diagrama BPMN ao nível do processo

Após os filtros, são criadas as tabelas no Data Warehouse, e as tabelas são populadas com os dados restantes da tabela de Staging.

3.7 Temperaturas

Para o processo ETL dos dados meteorológicos, o SSIS começa por executar um script em python através de um executável, onde irá à tabela de factos dos




Figura 7. Diagrama BPMN nível padrão para a dimensão tipo de incêndio

incêndios para poder recolher somente os dados meteorológicos para os dias e locais onde houveram incêndios, inserindo no final os dados para a Staging Area.

Após os dados estarem na base de dados de Staging, são criadas e populadas as dimensões e a tabela de factos na base de dados do Data Warehouse. Como os dados meteorológicos são recolhidos apenas para os dias e locais específicos, e como os dados vêm diretamente do *Open Meteo*, logo não é necessário fazer qualquer filtro após os dados entrarem na Staging Area.

Como este processo utiliza os dados da tabela de factos dos incêndios, logo, este processo tem como precedência a execução do processo ETL da secção 3.6.

3.8 Cobertura Mediática

Neste processo, não foi colocado o executável responsável pela extração de notícias, pois, este para além de fazer a extração das notícias, ainda é necessário fazer um processo de povoamento onde são criados mais campos através de um modelo de machine learning. Podendo esse processo consumir bastante tempo, logo, não foi colocado no processo ETL, de modo a ser mais simples de o exemplificar.

Portanto, para este processo funcionar é necessário existir dentro do respetivo diretório do SSIS o ficheiro JSON com os dados já populados pelo modelo de machine learning. A partir desse ficheiro, o SSIS irá inserir os dados na Staging Area a partir de um executável já existente. Com os dados lá dentro, irá popular todas as tabelas do respetivo esquema em estrela através de scripts em T-SQL.

3.9 Vegetação




Figura 8. Diagrama BPMN nível padrão para dimensão dia




Figura 9. Diagrama BPMN nível padrão para tabela de factos de incêndio




Figura 10. Diagrama BPMN nível padrão para a dimensão de localização




Figura 11. Processo ETL para incêndios




Figura 12. Processo ETL para temperaturas




Figura 13. Processo ETL para cobertura mediática

4 Resultados e Discussão

5 Conclusões e Trabalho Futuro