

Business Intelligence para a Análise de Incêndios Florestais

Hugo Guimarães^[8220337], Nuno Silva^[8180393], Diogo Pereira^[8200594], and Duarte Sampaio^[8190553]

Escola Superior de Tecnologia e Gestão
<https://www.estg.ipp.pt/>

Resumo Este trabalho apresenta o desenvolvimento de um sistema de Business Intelligence para análise de incêndios florestais em Portugal Continental (2020-2025). O projeto assenta na construção de um Data Warehouse dimensional que integra dados do ICNF, informação meteorológica (Open-Meteo), índices de vegetação NDVI (MODIS), cobertura do solo (CORINE Land Cover), e indicadores socioeconómicos (INE). O processo ETL desenvolvido garante a extração, transformação e integração das diversas fontes de dados. A modelação dimensional segue a metodologia de Kimball, identificando quatro processos de negócio: Ocorrência de Incêndio, Meteorologia Diária, Operações de Combate e Monitorização de Vegetação. O sistema permite análises sobre áreas de risco, sazonalidade, impacto meteorológico, influência da vegetação, eficácia dos meios de combate e impacto socioeconómico. A visualização é realizada através de dashboards interativos em Microsoft Power BI, proporcionando uma ferramenta de apoio à decisão para entidades responsáveis pela prevenção e combate a incêndios florestais.

Keywords: Data Warehouse · Business Intelligence · Incêndios Florestais · ETL · Modelação Dimensional · Power BI · NDVI · Portugal · Apoio à Decisão

1 Definição do Problema

1.1 Dataset

ICNF O principal conjunto de dados consiste numa versão filtrada dos registos do repositório `icnf_fire_data`¹, que agrega ocorrências do serviço `fogos.icnf.pt`. Para este estudo foram considerados apenas os incêndios entre 2020 e 2025, após remoção de registos irrelevantes, nomeadamente:

- registos com coordenadas em falta;
- incêndios com área ardida inferior a 0.1 hectares;
- queimadas controladas;
- ocorrências não classificadas como incêndios;
- registos sem data/hora de início ou fim.

Meteorologia A partir dos dados recolhidos de cada incêndio, construiu-se um script que faz chamadas à API do *open-meteo*² de modo a conseguir o máximo de informação meteorológica para cada dia em que cada incêndio esteve ativo.

RSS Google News Foram recolhidos artigos noticiosos usando filtros por idioma (português), termos-chave e período (2020–2025). Extraíram-se metadados (título, data, fonte, URL). Ainda não foi definida a utilização final destes dados, mas visam complementar informação sobre meios e cobertura mediática.

MODIS — MOD13Q1 (NDVI) Será usado o produto MOD13Q1 (NDVI 16-day, 250 m) através do Google Earth Engine. Para cada perímetro de incêndio serão calculadas estatísticas zonais pré e pós-incêndio (média, contagem de píxeis, etc.). O período foco é 2020–2024.

CORINE Land Cover Usado para atribuir classes de uso do solo a perímetros de incêndio e para construir áreas de controlo. O produto base será o CLC 2018.

1.2 Objetivos

1. Identificar áreas com maior risco de incêndio;
2. Determinar épocas do ano com maior ocorrência de incêndios;
3. Identificar anos com maior número e gravidade de incêndios;
4. Analisar o impacto das temperaturas no número, gravidade e duração dos incêndios;
5. Avaliar a influência do estado da vegetação (NDVI) na probabilidade e severidade dos incêndios;
6. Avaliar o efeito do tipo de uso do solo na ocorrência e extensão dos incêndios;
7. Examinar como meios terrestres e aéreos afetam duração e gravidade;
8. Avaliar impactos nos níveis de freguesia.

¹ https://github.com/cityxdev/icnf_fire_data

² <https://open-meteo.com/>

1.3 Questões Analíticas

Apresentam-se pontos de análise associados aos objetivos (exemplos resumidos):

- Incêndios por zona/distrito/concelho; área ardida total; percentagem de área ardida.
- Sazonalidade: incêndios por mês/estação, área média por mês.
- Tendências anuais e classificação por severidade.
- Relação entre faixas de temperatura (média, máxima) e métricas de incêndio (contagem, área, duração).
- Correlações entre NDVI pré-incêndio e probabilidade de ocorrência; comparações com áreas de controlo.
- Distribuição de incêndios por classe CORINE; área média por classe.
- Métricas de eficácia dos meios (tempo de resposta, meios mobilizados, taxa de expansão antes/depois da intervenção).
- Indicadores socioeconómicos pré e pós-incêndio a nível de freguesia (população, emprego, turismo, valores imobiliários).

1.4 Identificação dos Processos de Negócio

- **Ocorrência de Incêndio:** registo do evento (localização, duração, área, causa).
- **Meteorologia Diária:** registo de condições meteorológicas por dia/ local.
- **Operações de Combate:** registo de meios mobilizados, tempos e eficácia.
- **Monitorização de Vegetação:** medições periódicas de índices (NDVI) e classificação.

1.5 Metodologia

Apresenta-se, de forma concisa, a abordagem metodológica seguida para modelação dimensional e desenho do processo ETL. Adotámos a abordagem orientada aos processos de negócio (Kimball), identificando o grão, as principais dimensões e as medidas para cada processo. Abaixo descrevem-se os quatro processos identificados, cada um com o respetivo grão e medidas principais.

Ocorrência de Incêndio Grão: cada linha representa um incêndio (evento) identificado pelo `incident_id`.

Principais dimensões: tipo de incêndio, entidade regista (ICNF), data/hora de início e fim, localização (coordenadas, freguesia, concelho, distrito).

Medidas principais: área ardida (ha), duração (horas), número de focos iniciais. Medidas derivadas a considerar: severidade (índice composto) e taxa de expansão (ha/h).

Meteorologia Diária Grão: registo diário de condições meteorológicas associado a uma localização ou a um perímetro de incêndio.

Medidas principais: temperatura média e máxima ($^{\circ}\text{C}$), humidade relativa (%), velocidade do vento (km/h), precipitação (mm). Estes valores servem para calcular indicadores derivados (ex.: número de dias com temperatura acima de um limiar, soma de precipitação no período do incêndio).

Operações de Combate Grão: cada registo corresponde a uma operação ou intervenção num incêndio específico.

Medidas principais: número de operacionais mobilizados, veículos terrestres, meios aéreos, tempo de resposta inicial (min), tempo total de operação/contensão e eficácia estimada da contenção. Serão também registadas datas/horas de chegada dos meios para análises temporais.

Monitorização de Vegetação Grão: medições de índice de vegetação (por ex., NDVI) agregadas por perímetro e por janela temporal (pré/post-incêndio).

Medidas principais: NDVI médio pré-incêndio, NDVI médio pós-incêndio, contagem de píxeis válidos, variação percentual. Estas medidas serão usadas em análises comparativas e como variáveis explicativas em modelos estatísticos.

Notas sobre modelação e ETL O desenho do Data Warehouse segue princípios dimensionais: tabelas de factos centradas nos processos acima e dimensões partilhadas (tempo, local, tipo de uso do solo — CORINE, e entidades). O processo ETL inclui etapas de validação (remoção de registos com coordenadas em falta, filtro por área mínima, padronização de datas), enriquecimento (junção com meteorologia e NDVI) e agregação (fichas resumo por `incident_id`).

Esta organização pretende facilitar a leitura num formato de artigo, concentrando a discussão metodológica numa subsecção sucinta e orientada para as decisões de modelação.

2 Análise de Perfil (Data Profiling)

O Data Profiling constitui uma etapa fundamental para o processo de análise exploratória de dados, onde é possível compreender a estrutura, qualidade e características dos datasets antes da construção do Data Warehouse. Esta secção apresenta a análise detalhada dos dados provenientes do Instituto da Conservação da Natureza e das Florestas (ICNF).

A análise incide sobre 23 variáveis cuidadosamente selecionadas pela sua relevância para os objetivos analíticos do projeto, abrangendo dimensões geográficas, temporais, de severidade e de contexto meteorológico das ocorrências.

Os restantes conjuntos de dados (Open-Meteo e outros) foram recolhidos e integrados com base nos dados de latitude e longitude e datas presentes no dataset do ICNF. Desta forma, a análise de perfil focou-se no dataset principal, que serve como base para todo o sistema.

2.1 Análise de Completude

A análise de valores nulos revelou alguns padrões de incompletude de algumas variáveis, sendo as principais, as variáveis meteorológicas, onde são apresentadas taxas de ausência significativas, refletindo limitações na cobertura da rede de estações meteorológicas ou períodos anteriores onde estes dados não eram sistematicamente registados.

A ausência de valores em quase 30% nas variáveis de clima fortalece a decisão tomada inicialmente de procurar dados sobre as mesmas no *open-meteo*, assim, estes valores são ignorados do dataset do ICNF, garantindo não só mais variáveis de climatização, como também a garantia que as mesmas irão sempre existir.

As variáveis de classificação (TIPO, CAUSA, TIPOCAUSA) apresentam melhor completude, com taxas de preenchimento superiores a 93%, indicando robustez no processo de registo operacional destas características fundamentais. No entanto, mesmo tendo percentagens de valores nulos bastante baixos, tanto os registos com as variáveis da família do CAUSA (CAUSA, TIPOCAUSA, CAUSAFAMILIA) como as variáveis FPMC e FWI com valores nulos, irão ser colocados em tabelas de quarentena para posterior validação e possível tratamento, uma vez que são variáveis cruciais para a análise de incêndios florestais.

Tabela 1. Percentagem de valores nulos por coluna

Coluna	Percentagem Nulos	Total Nulos	Total Registos
TEMPERATURA	29.9	732	2451
HUMIDADERELATIVA	29.9	732	2451
CAUSA	7.5	184	2451
TIPOCAUSA	7.5	184	2451
CAUSAFAMILIA	7.5	184	2451
FPMC	0.2	6	2451
FWI	0.2	6	2451

2.2 Unicidade dos dados

Algo bastante importante de averiguar no dataset, é se existem registos duplicados, visto que isso poluiria o data warehouse, podendo atrapalhar a análise dos dados, ou, mais importante, se existe algum id repetido.

Após analisar todos os registos, foi possível constatar que para além de não existirem ids repetidos, também não existem registos inteiramente iguais entre si, confirmando assim a unicidade do dataset. Isto indica também que a origem dos dados (ICNF) mantém um controlo adequado sobre as entradas dos registos, eliminando assim a necessidade de operações de deduplicação dos dados no processo de integração, e reforça a fiabilidade de análises posteriores, dado que não vão existir duplicações que poderão distorcer as estatísticas.

2.3 Detecção e Caracterização de Outliers

A Figura 1 apresenta os boxplots para as oito variáveis numéricas do dataset, revelando padrões de distribuição e outliers característicos dos fenómenos em estudo:

Variáveis de Área Ardida (AREATOTAL, AREAMATO, AREAPOV, AREAAGRIC): Observa-se uma forte assimetria positiva, com a maioria das ocorrências concentrada em valores baixos (pequenos incêndios) e uma cauda longa de outliers extremos correspondentes a grandes incêndios florestais. Esta distribuição reflete a natureza do fenómeno, onde eventos raros mas catastróficos têm impacto desproporcional. Os outliers superiores não são erros mas sim eventos genuínos que devem ser preservados na análise.

Variáveis Meteorológicas: A TEMPERATURA apresenta distribuição mais simétrica, com outliers em ambas as caudas refletindo condições meteorológicas extremas. A HUMIDADERELATIVA mostra concentração em valores médios-altos, com outliers inferiores associados a períodos de seca críticos para propagação de incêndios.

Índices de Perigo (FFMC, FWI): O FFMC (Fine Fuel Moisture Code) apresenta outliers superiores indicativos de condições extremas de secura de combustíveis finos. O FWI (Fire Weather Index) mostra padrão semelhante, com valores extremos sinalizando dias de perigo excepcional.

2.4 Análise da Distribuição Espacial das Ocorrências

A análise da distribuição geográfica por distrito (Figura 2) revela um grande padrão de concentração espacial. Os distritos do interior Norte e Centro do país dominam claramente as estatísticas, refletindo a conjugação de fatores como maior cobertura florestal, condições climáticas mais propícias, e características sócio-económicas das populações rurais.

Os três distritos com maior incidência acumulam uma proporção significativa do total de ocorrências, evidenciando a necessidade de políticas de prevenção geograficamente diferenciadas. Esta concentração justifica também a inclusão da dimensão geográfica como eixo central de análise no Data Warehouse.




Figura 1. Bloxplot Individuais das variáveis escolhidas do ICNF

A desagregação ao nível da freguesia (Figura 3) revela hotspots localizados onde a recorrência é particularmente elevada. Esta granularidade é essencial para:

- Identificação de áreas prioritárias para investimento em prevenção
- Análise de padrões de reincidência espacial
- Correlação com características locais (tipo de vegetação, densidade populacional, acessibilidades)

Observa-se que as freguesias com maior número de ocorrências não coincidem necessariamente com as de maior área ardida, sugerindo diferenças na eficiência de combate ou em características de propagação.




Figura 2. Top 20 distritos com maior frequência de ocorrências de incêndio




Figura 3. Top 20 freguesias com maior frequência de ocorrências de incêndio

2.5 Análise Causal

A análise de causas (Figura 4) constitui uma das dimensões mais relevantes para políticas públicas. O gráfico evidencia a distribuição entre causas humanas (intencionais, negligentes, acidentais) e causas naturais (principalmente raios).

A predominância de causas humanas sobre naturais, caso verificada, sublinha a importância de campanhas de sensibilização e fiscalização. A categoria "Desconhecida" ou "Em investigação" pode representar uma limitação dos dados que deve ser considerada na interpretação dos resultados analíticos.




Figura 4. Distribuição das Ocorrências por Tipo de Causa

Algo a realçar, é que tanto nesta secção como na secção 2.4 não foi realizado nenhum tipo de tratamento categórico nas variáveis antes de formular os gráficos de barras. E mesmo sem esse tratamento, não apareceram variáveis repetidas com nomes ligeiramente diferentes, isso significa que não existe nenhum tipo de incoerência nos valores das variáveis que iram obrigar a futura utilização das tabelas de dicionário.

2.6 Relações entre as variáveis

A matriz de correlações (Figura 5) revela as interdependências entre variáveis numéricas, essenciais para:

Correlações Fortes Esperadas:

- **AREATOTAL vs. AREAMATO/AREAPOV:** Correlações positivas fortes ($r > 0.7$), indicando que estes são os principais componentes contribuidores para a área total. A magnitude relativa das correlações indica qual tipo de vegetação domina.




Figura 5. Matriz de correlações entre variáveis numéricas

- **TEMPERATURA vs. HUMIDADERELATIVA:** Correlação negativa esperada ($r < -0.5$), refletindo a relação física inversa entre estas variáveis.
- **FFMC vs. FWI:** Correlação positiva forte, dado que o FFMC é um dos componentes do índice composto FWI.

Correlações Moderadas de Interesse:

- **Índices meteorológicos vs. Área ardida:** Correlações positivas moderadas sugerem que condições meteorológicas adversas contribuem para incêndios maiores, mas não determinam completamente a severidade (outros fatores como tempo de resposta e meios disponíveis são relevantes).
- **TEMPERATURA vs. Área ardida:** Correlação positiva esperada, validando o papel das ondas de calor na severidade dos incêndios.

3 Implementação da Solução

3.1 Arquitetura Geral

A arquitetura implementada para o sistema de suporte analítico assenta num processo de integração que reúne dados provenientes de diferentes fontes, aplica transformações adequadas e prepara a sua posterior carga no repositório analítico. Esta secção apresenta a visão geral do fluxo de dados e dos componentes envolvidos, permitindo compreender como a informação é organizada antes de ser disponibilizada no armazém de dados.

A Figura 6 representa a arquitetura do processo ELT utilizado no sistema analítico. No lado esquerdo encontram-se as fontes de dados. Estas incluem ficheiros fornecidos pelo ICNF, dados meteorológicos em formato bruto e informação proveniente da internet como a cobertura mediática. Os dados extraídos seguem para a área de preparação onde ocorre a transformação. Esta área inclui estruturas de suporte, um espaço de quarentena para validação e a camada de transformação que organiza os dados em zonas específicas de integração. Após a preparação, a informação é enviada para a área de carregamento onde é finalmente armazenada no data warehouse.




Figura 6. Arquitetura ELT (Estrutura da DSA)

3.2 Fluxos de Processamento

A modelação do processo ETL é complementada pela criação de diagramas BPMN que permitem representar de forma clara e sistemática o fluxo de atividades envolvidas na preparação dos dados que irão alimentar o data warehouse. Estes diagramas facilitam a compreensão das várias fases do processo, permitindo identificar dependências e contribuem para a deteção de possíveis pontos de melhoria na execução das tarefas.

Existem três níveis de diagramas BPMN que representam a aplicação do processo ETL, sendo eles: nível do processo; nível padrão e nível da tarefa. Sendo que, no âmbito deste projeto, não foi necessário a especificação dos diagramas ao nível da tarefa, como também não foram descritos de forma individual todos os processos ao nível padrão, visto que são todos bastante semelhantes entre si

3.3 Visão Global do Processo

Esta subsecção irá acolher o diagrama BPMN ao nível do processo. O objetivo deste nível é oferecer uma visão abrangente das principais etapas que compõem o fluxo do processo ETL, desde a obtenção das fontes de dados até ao carregamento final no data warehouse. A representação global permitirá compreender a articulação entre as atividades nucleares do sistema, bem como o percurso lógico seguido pelos dados ao longo de todo o ciclo de tratamento.

3.4 Detalhe de Atividades Específicas

Algumas partes do processo ETL serão representadas por diagramas BPMN ao nível padrão. Estes diagramas permitem aprofundar tarefas que exigem uma descrição mais granular, como procedimentos de validação, mecanismos de controlo de qualidade ou etapas específicas de transformação e enriquecimento dos dados provenientes das diferentes fontes.

3.5 Detalhes do ETL

O presente capítulo detalha a arquitetura e o desenvolvimento do processo de ETL (Extract, Transform, Load). Para a orquestração e execução dos fluxos de dados, recorreu-se à plataforma Microsoft SQL Server Integration Services (SSIS). O objetivo central desta etapa foi garantir a integridade, limpeza e estruturação dos dados provenientes de fontes heterogêneas antes de serem carregadas para o Data Warehouse. Esta secção explora as especificidades de implementação para cada conjunto de dados temático.

3.6 Incêndios

Para fazer o processo de ETL para os dados provenientes do ICNF, gerou-se um executável do script de extração dos dados do ICNF, e criou-se outro responsável por inserir os dados na Staging Area. Esta abordagem foi escolhida porque o SISS não apresenta mecanismos simples para a gestão de dados em formato CSV, portanto, por simplicidade, tanto neste processo como nos restantes, a manipulação dos dados, antes de serem carregados para a base de dados de staging, é realizada em python através de um executável.

Com os dados dentro da Staging Area, são realizados vários filtros através de scripts em T-SQL, para poder: remover valores nulos de latitude e longitude; e remover incêndios cuja zona queimada não seja significativa (superior a 0.1 hectares).




Figura 7. Diagrama BPMN ao nível do processo

Após os filtros, são criadas as tabelas no Data Warehouse, e as tabelas são populadas com os dados restantes da tabela de Staging.

3.7 Temperaturas

Para o processo ETL dos dados meteorológicos, o SSIS começa por executar um script em pyhton através de um executável, onde irá à tabela de factos dos




Figura 8. Diagrama BPMN nível padrão para a dimensão tipo de incêndio

incêndios para poder recolher somente os dados meteorológicos para os dias e locais onde houveram incêndios, inserindo no final os dados para a Staging Area.

Após os dados estarem na base de dados de Staging, são criadas e populadas as dimensões e a tabela de factos na base de dados do Data Warehouse. Como os dados meteorológicos são recolhidos apenas para os dias e locais específicos, e como os dados vêm diretamente do *Open Meteo*, logo não é necessário fazer qualquer filtro após os dados entrarem na Staging Area.




Como este processo utiliza os dados da tabela de factos dos incêndios, logo, este processo tem como precedência a execução do processo ETL da secção 3.6.

3.8 Cobertura Mediática

Neste processo, não foi colocado o executável responsável pela extração de notícias, pois, este para além de fazer a extração das notícias, ainda é necessário fazer um processo de povoamento onde são criados mais campos através de um modelo de machine learning. Podendo esse processo consumir bastante tempo, logo, não foi colocado no processo ETL, de modo a ser mais simples de o exemplificar.

Portanto, para este processo funcionar é necessário existir dentro do respetivo diretório do SSIS o ficheiro JSON com os dados já populados pelo modelo de machine learning. A partir desse ficheiro, o SSIS irá inserir os dados na Staging Area a partir de um executável já existente. Com os dados lá dentro, irá popular todas as tabelas do respetivo esquema em estrela através de scripts em T-SQL.

3.9 Vegetação






Figura 12. Processo ETL para incêndios




Figura 13. Processo ETL para temperaturas




Figura 14. Processo ETL para cobertura mediática