

Business Intelligence para a Análise de Incêndios Florestais

Hugo Guimarães^[8220337], Nuno Silva^[8180393], Diogo Pereira^[8200594], and Duarte Sampaio^[8190553]

Escola Superior de Tecnologia e Gestão
<https://www.estg.ipp.pt/>

Resumo Este trabalho apresenta o desenvolvimento de um sistema de Business Intelligence para análise de incêndios florestais em Portugal Continental (2020-2025). O projeto assenta na construção de um Data Warehouse dimensional que integra dados do ICNF, informação meteorológica (Open-Meteo), índices de vegetação NDVI (MODIS), cobertura do solo (CORINE Land Cover), e indicadores socioeconómicos (INE). O processo ETL desenvolvido garante a extração, transformação e integração das diversas fontes de dados. A modelação dimensional segue a metodologia de Kimball, identificando quatro processos de negócio: Ocorrência de Incêndio, Meteorologia Diária, Operações de Combate e Monitorização de Vegetação. O sistema permite análises sobre áreas de risco, sazonalidade, impacto meteorológico, influência da vegetação, eficácia dos meios de combate e impacto socioeconómico. A visualização é realizada através de dashboards interativos em Microsoft Power BI, proporcionando uma ferramenta de apoio à decisão para entidades responsáveis pela prevenção e combate a incêndios florestais.

Keywords: Data Warehouse · Business Intelligence · Incêndios Florestais · ETL · Modelação Dimensional · Power BI · NDVI · Portugal · Apoio à Decisão

1 Análise de Perfil (Data Profiling)

O Data Profiling constitui uma etapa fundamental para o processo de análise exploratória de dados, onde é possível compreender a estrutura, qualidade e características dos datasets antes da construção do Data Warehouse. Esta secção apresenta a análise detalhada dos dados provenientes do Instituto da Conservação da Natureza e das Florestas (ICNF).

A análise incide sobre 23 variáveis cuidadosamente seleccionadas pela sua relevância para os objetivos analíticos do projeto, abrangendo dimensões geográficas, temporais, de severidade e de contexto meteorológico das ocorrências.

Os restantes conjuntos de dados (Open-Meteo e outros) foram recolhidos e integrados com base nos dados de latitude e longitude e datas presentes no dataset do ICNF. Desta forma, a análise de perfil focou-se no dataset principal, que serve como base para todo o sistema.

1.1 Análise de Completude

A análise de valores nulos revelou alguns padrões de incompletude de algumas variáveis, sendo as principais, as variáveis meteorológicas, onde são apresentadas taxas de ausência significativas, refletindo limitações na cobertura da rede de estações meteorológicas ou períodos anteriores onde estes dados não eram sistematicamente registados.

A ausência de valores em quase 30% nas variáveis de clima fortalece a decisão tomada inicialmente de procurar dados sobre as mesmas no *open-meteo*, assim, estes valores são ignorados do dataset do ICNF, garantindo não só mais variáveis de climatização, como também a garantia que as mesmas irão sempre existir.

As variáveis de classificação (TIPO, CAUSA, TIPOCAUSA) apresentam melhor completude, com taxas de preenchimento superiores a 93%, indicando robustez no processo de registo operacional destas características fundamentais.

Tabela 1. Percentagem de valores nulos por coluna

Coluna	Percentagem	Nulos Total	Nulos Total	Registos
TEMPERATURA	29.9	732		2451
HUMIDADERELATIVA	29.9	732		2451
CAUSA	7.5	184		2451
TIPOCAUSA	7.5	184		2451
CAUSAFAMILIA	7.5	184		2451
FFMC	0.2	6		2451
FWI	0.2	6		2451

1.2 Detecção e Caracterização de Outliers

A Figura 1 apresenta os boxplots para as oito variáveis numéricas do dataset, revelando padrões de distribuição e outliers característicos dos fenômenos em estudo:




Figura 1. Bloxplot Individuais das variáveis escolhidas do ICNF

Variáveis de Área Ardida (AREATOTAL, AREAMATO, AREAPOV, AREAAGRIC): Observa-se uma forte assimetria positiva, com a maioria das ocorrências concentrada em valores baixos (pequenos incêndios) e uma cauda longa de outliers extremos correspondentes a grandes incêndios florestais. Esta distribuição reflete a natureza do fenómeno, onde eventos raros mas catas-

tróficos têm impacto desproporcional. Os outliers superiores não são erros mas sim eventos genuínos que devem ser preservados na análise.

Variáveis Meteorológicas: A TEMPERATURA apresenta distribuição mais simétrica, com outliers em ambas as caudas refletindo condições meteorológicas extremas. A HUMIDADE RELATIVA mostra concentração em valores médios-altos, com outliers inferiores associados a períodos de seca críticos para propagação de incêndios.

Índices de Perigo (FFMC, FWI): O FFMC (Fine Fuel Moisture Code) apresenta outliers superiores indicativos de condições extremas de secura de combustíveis finos. O FWI (Fire Weather Index) mostra padrão semelhante, com valores extremos sinalizando dias de perigo excepcional.

1.3 Análise da Distribuição Espacial das Ocorrências

A análise da distribuição geográfica por distrito (Figura 2) revela um grande padrão de concentração espacial. Os distritos do interior Norte e Centro do país dominam claramente as estatísticas, refletindo a conjugação de fatores como maior cobertura florestal, condições climáticas mais propícias, e características socioeconómicas das populações rurais.

Os três distritos com maior incidência acumulam uma proporção significativa do total de ocorrências, evidenciando a necessidade de políticas de prevenção geograficamente diferenciadas. Esta concentração justifica também a inclusão da dimensão geográfica como eixo central de análise no Data Warehouse.




Figura 2. Top 20 distritos com maior frequência de ocorrências de incêndio

A desagregação ao nível da freguesia (Figura 3) revela hotspots localizados onde a recorrência é particularmente elevada. Esta granularidade é essencial para:

- Identificação de áreas prioritárias para investimento em prevenção
- Análise de padrões de reincidência espacial
- Correlação com características locais (tipo de vegetação, densidade populacional, acessibilidades)

Observa-se que as freguesias com maior número de ocorrências não coincidem necessariamente com as de maior área ardida, sugerindo diferenças na eficiência de combate ou em características de propagação.




Figura 3. Top 20 freguesias com maior frequência de ocorrências de incêndio

1.4 Análise Causal

A análise de causas (Figura 4) constitui uma das dimensões mais relevantes para políticas públicas. O gráfico evidencia a distribuição entre causas humanas (intencionais, negligentes, acidentais) e causas naturais (principalmente raios).

A predominância de causas humanas sobre naturais, caso verificada, sublinha a importância de campanhas de sensibilização e fiscalização. A categoria "Desconhecida" ou "Em investigação" pode representar uma limitação dos dados que deve ser considerada na interpretação dos resultados analíticos.

Algo a realçar, é que tanto nesta secção como na secção 1.3 não foi realizado nenhum tipo de tratamento categórico nas variáveis antes de formular os gráficos de barras. E mesmo sem esse tratamento, não apareceram variáveis repetidas mas com nomes ligeiramente diferentes, isso significa que não existe nenhum tipo de incoerência nos valores das variáveis que iram obrigar a futura utilização das tabelas de dicionário.




Figura 4. Distribuição das Ocorrências por Tipo de Causa

1.5 Relações entre as variáveis

A matriz de correlações (Figura 5) revela as interdependências entre variáveis numéricas, essenciais para:

Correlações Fortes Esperadas:

- **AREATOTAL vs. AREAMATO/AREAPOV:** Correlações positivas fortes ($r > 0.7$), indicando que estes são os principais componentes contribuidores para a área total. A magnitude relativa das correlações indica qual tipo de vegetação domina.
- **TEMPERATURA vs. HUMIDADERELATIVA:** Correlação negativa esperada ($r < -0.5$), refletindo a relação física inversa entre estas variáveis.
- **FFMC vs. FWI:** Correlação positiva forte, dado que o FFMC é um dos componentes do índice composto FWI.

Correlações Moderadas de Interesse:

- **Índices meteorológicos vs. Área ardida:** Correlações positivas moderadas sugerem que condições meteorológicas adversas contribuem para incêndios maiores, mas não determinam completamente a severidade (outros fatores como tempo de resposta e meios disponíveis são relevantes).
- **TEMPERATURA vs. Área ardida:** Correlação positiva esperada, validando o papel das ondas de calor na severidade dos incêndios.




Figura 5. Matriz de correlações entre variáveis numéricas

Acknowledgments. A bold run-in heading in small font size at the end of the paper is used for general acknowledgments, for example: This study was funded by X (grant number Y).

Disclosure of Interests. It is now necessary to declare any competing interests or to specifically state that the authors have no competing interests. Please place the statement with a bold run-in heading in small font size beneath the (optional) acknowledgments¹, for example: The authors have no competing interests to declare that are relevant to the content of this article. Or: Author A has received research grants from Company W. Author B has received a speaker honorarium from Company X and owns stock in Company Y. Author C is a member of committee Z.

Referências

1. Author, F.: Article title. Journal **2**(5), 99–110 (2016)
2. Author, F., Author, S.: Title of a proceedings paper. In: Editor, F., Editor, S. (eds.) CONFERENCE 2016, LNCS, vol. 9999, pp. 1–13. Springer, Heidelberg (2016). <https://doi.org/10.1007/1234567890>
3. Author, F., Author, S., Author, T.: Book title. 2nd edn. Publisher, Location (1999)
4. Author, A.-B.: Contribution title. In: 9th International Proceedings on Proceedings, pp. 1–2. Publisher, Location (2010)
5. LNCS Homepage, <http://www.springer.com/lncs>, last accessed 2023/10/25

¹ If EquinOCS, our proceedings submission system, is used, then the disclaimer can be provided directly in the system.