

Business Intelligence para a Análise de Incêndios Florestais

Hugo Guimarães^[8220337], Nuno Silva^[8180393], Diogo Pereira^[8200594], and Duarte Sampaio^[8190553]

Escola Superior de Tecnologia e Gestão
<https://www.estg.ipp.pt/>

Resumo Este trabalho apresenta o desenvolvimento de um sistema de Business Intelligence para análise de incêndios florestais em Portugal Continental (2020-2025). O projeto assenta na construção de um Data Warehouse dimensional que integra dados do ICNF, informação meteorológica (Open-Meteo), índices de vegetação NDVI (MODIS), cobertura do solo (CORINE Land Cover), e indicadores socioeconómicos (INE). O processo ETL desenvolvido garante a extração, transformação e integração das diversas fontes de dados. A modelação dimensional segue a metodologia de Kimball, identificando quatro processos de negócio: Ocorrência de Incêndio, Meteorologia Diária, Operações de Combate e Monitorização de Vegetação. O sistema permite análises sobre áreas de risco, sazonalidade, impacto meteorológico, influência da vegetação, eficácia dos meios de combate e impacto socioeconómico. A visualização é realizada através de dashboards interativos em Microsoft Power BI, proporcionando uma ferramenta de apoio à decisão para entidades responsáveis pela prevenção e combate a incêndios florestais.

Keywords: Data Warehouse · Business Intelligence · Incêndios Florestais · ETL · Modelação Dimensional · Power BI · NDVI · Portugal · Apoio à Decisão

1 Análise de Perfil (Data Profiling)

O Data Profiling constitui uma etapa fundamental para o processo de análise exploratória de dados, onde é possível compreender a estrutura, qualidade e características dos datasets antes da construção do Data Warehouse. Esta secção apresenta a análise detalhada dos dados provenientes do Instituto da Conservação da Natureza e das Florestas (ICNF).

A análise incide sobre 23 variáveis cuidadosamente selecionadas pela sua relevância para os objetivos analíticos do projeto, abrangendo dimensões geográficas, temporais, de severidade e de contexto meteorológico das ocorrências.

Os restantes conjuntos de dados (Open-Meteo e outros) foram recolhidos e integrados com base nos dados de latitude e longitude e datas presentes no dataset do ICNF. Desta forma, a análise de perfil focou-se no dataset principal, que serve como base para todo o sistema.

1.1 Análise de Completude

A análise de valores nulos revelou alguns padrões de incompletude de algumas variáveis, sendo as principais, as variáveis meteorológicas, onde são apresentadas taxas de ausência significativas, refletindo limitações na cobertura da rede de estações meteorológicas ou períodos anteriores onde estes dados não eram sistematicamente registados.

A ausência de valores em quase 30% nas variáveis de clima fortalece a decisão tomada inicialmente de procurar dados sobre as mesmas no *open-meteo*, assim, estes valores são ignorados do dataset do ICNF, garantindo não só mais variáveis de climatização, como também a garantia que as mesmas irão sempre existir.

As variáveis de classificação (TIPO, CAUSA, TIPOCAUSA) apresentam melhor completude, com taxas de preenchimento superiores a 93%, indicando robustez no processo de registo operacional destas características fundamentais. No entanto, mesmo tendo percentagens de valores nulos bastante baixos, tanto os registos com as variáveis da família do CAUSA (CAUSA, TIPOCAUSA, CAUSAFAMILIA) como as variáveis FPMC e FWI com valores nulos, irão ser colocados em tabelas de quarentena para posterior validação e possível tratamento, uma vez que são variáveis cruciais para a análise de incêndios florestais.

Tabela 1. Percentagem de valores nulos por coluna

Coluna	Percentagem Nulos	Total Nulos	Total Registos
TEMPERATURA	29.9	732	2451
HUMIDADERELATIVA	29.9	732	2451
CAUSA	7.5	184	2451
TIPOCAUSA	7.5	184	2451
CAUSAFAMILIA	7.5	184	2451
FPMC	0.2	6	2451
FWI	0.2	6	2451

1.2 Unicidade dos dados

Algo bastante importante de averiguar no dataset, é se existem registos duplicados, visto que isso poluiria o data warehouse, podendo atrapalhar a análise dos dados, ou, mais importante, se existe algum id repetido.

Após analisar todos os registos, foi possível constatar que para além de não existirem ids repetidos, também não existem registos inteiramente iguais entre si, confirmando assim a unicidade do dataset. Isto indica também que a origem dos dados (ICNF) mantém um controlo adequado sobre as entradas dos registos, eliminando assim a necessidade de operações de deduplicação dos dados no processo de integração, e reforça a fiabilidade de análises posteriores, dado que não vão existir duplicações que poderão distorcer as estatísticas.

1.3 Detecção e Caracterização de Outliers

A Figura 1 apresenta os boxplots para as oito variáveis numéricas do dataset, revelando padrões de distribuição e outliers característicos dos fenómenos em estudo:

Variáveis de Área Ardida (AREATOTAL, AREAMATO, AREAPOV, AREAAGRIC): Observa-se uma forte assimetria positiva, com a maioria das ocorrências concentrada em valores baixos (pequenos incêndios) e uma cauda longa de outliers extremos correspondentes a grandes incêndios florestais. Esta distribuição reflete a natureza do fenómeno, onde eventos raros mas catastróficos têm impacto desproporcional. Os outliers superiores não são erros mas sim eventos genuínos que devem ser preservados na análise.

Variáveis Meteorológicas: A TEMPERATURA apresenta distribuição mais simétrica, com outliers em ambas as caudas refletindo condições meteorológicas extremas. A HUMIDADERELATIVA mostra concentração em valores médios-altos, com outliers inferiores associados a períodos de seca críticos para propagação de incêndios.

Índices de Perigo (FFMC, FWI): O FFMC (Fine Fuel Moisture Code) apresenta outliers superiores indicativos de condições extremas de secura de combustíveis finos. O FWI (Fire Weather Index) mostra padrão semelhante, com valores extremos sinalizando dias de perigo excepcional.

1.4 Análise da Distribuição Espacial das Ocorrências

A análise da distribuição geográfica por distrito (Figura 2) revela um grande padrão de concentração espacial. Os distritos do interior Norte e Centro do país dominam claramente as estatísticas, refletindo a conjugação de fatores como maior cobertura florestal, condições climáticas mais propícias, e características sócio-económicas das populações rurais.

Os três distritos com maior incidência acumulam uma proporção significativa do total de ocorrências, evidenciando a necessidade de políticas de prevenção geograficamente diferenciadas. Esta concentração justifica também a inclusão da dimensão geográfica como eixo central de análise no Data Warehouse.




Figura 1. Bloxplot Individuais das variáveis escolhidas do ICNF

A desagregação ao nível da freguesia (Figura 3) revela hotspots localizados onde a recorrência é particularmente elevada. Esta granularidade é essencial para:

- Identificação de áreas prioritárias para investimento em prevenção
- Análise de padrões de reincidência espacial
- Correlação com características locais (tipo de vegetação, densidade populacional, acessibilidades)

Observa-se que as freguesias com maior número de ocorrências não coincidem necessariamente com as de maior área ardida, sugerindo diferenças na eficiência de combate ou em características de propagação.




Figura 2. Top 20 distritos com maior frequência de ocorrências de incêndio




Figura 3. Top 20 freguesias com maior frequência de ocorrências de incêndio

1.5 Análise Causal

A análise de causas (Figura 4) constitui uma das dimensões mais relevantes para políticas públicas. O gráfico evidencia a distribuição entre causas humanas (intencionais, negligentes, acidentais) e causas naturais (principalmente raios).

A predominância de causas humanas sobre naturais, caso verificada, sublinha a importância de campanhas de sensibilização e fiscalização. A categoria "Desconhecida" ou "Em investigação" pode representar uma limitação dos dados que deve ser considerada na interpretação dos resultados analíticos.




Figura 4. Distribuição das Ocorrências por Tipo de Causa

Algo a realçar, é que tanto nesta secção como na secção 1.4 não foi realizado nenhum tipo de tratamento categórico nas variáveis antes de formular os gráficos de barras. E mesmo sem esse tratamento, não apareceram variáveis repetidas com nomes ligeiramente diferentes, isso significa que não existe nenhum tipo de incoerência nos valores das variáveis que iram obrigar a futura utilização das tabelas de dicionário.

1.6 Relações entre as variáveis

A matriz de correlações (Figura 5) revela as interdependências entre variáveis numéricas, essenciais para:

Correlações Fortes Esperadas:

- **AREATOTAL vs. AREAMATO/AREAPOV:** Correlações positivas fortes ($r > 0.7$), indicando que estes são os principais componentes contribuidores para a área total. A magnitude relativa das correlações indica qual tipo de vegetação domina.




Figura 5. Matriz de correlações entre variáveis numéricas

- **TEMPERATURA vs. HUMIDADE RELATIVA:** Correlação negativa esperada ($r < -0.5$), refletindo a relação física inversa entre estas variáveis.
- **FFMC vs. FWI:** Correlação positiva forte, dado que o FFMC é um dos componentes do índice composto FWI.

Correlações Moderadas de Interesse:

- **Índices meteorológicos vs. Área ardida:** Correlações positivas moderadas sugerem que condições meteorológicas adversas contribuem para incêndios maiores, mas não determinam completamente a severidade (outros fatores como tempo de resposta e meios disponíveis são relevantes).
- **TEMPERATURA vs. Área ardida:** Correlação positiva esperada, validando o papel das ondas de calor na severidade dos incêndios.

2 Diagramas BPMN

A modelação do processo ETL é complementada pela criação de diagramas BPMN que permitem representar de forma clara e sistemática o fluxo de atividades envolvidas na preparação dos dados que irão alimentar o data warehouse. Estes diagramas facilitam a compreensão das várias fases do processo, permitindo identificar dependências e contribuem para a deteção de possíveis pontos de melhoria na execução das tarefas.

Existem três níveis de diagramas BPMN que representam a aplicação do processo ETL, sendo eles: nível do processo; nível padrão e nível da tarefa. Sendo que, no âmbito deste projeto, não foi necessário a especificação dos diagramas ao nível da tarefa, como também não foram descritos de forma individual todos os processos ao nível padrão, visto que são todos bastante semelhantes entre si

2.1 Visão Global do Processo

Esta subsecção irá acolher o diagrama BPMN ao nível do processo. O objetivo deste nível é oferecer uma visão abrangente das principais etapas que compõem o fluxo do processo ETL, desde a obtenção das fontes de dados até ao carregamento final no data warehouse. A representação global permitirá compreender a articulação entre as atividades nucleares do sistema, bem como o percurso lógico seguido pelos dados ao longo de todo o ciclo de tratamento.

2.2 Detalhe de Atividades Específicas

Algumas partes do processo ETL serão representadas por diagramas BPMN ao nível padrão. Estes diagramas permitem aprofundar tarefas que exigem uma descrição mais granular, como procedimentos de validação, mecanismos de controlo de qualidade ou etapas específicas de transformação e enriquecimento dos dados provenientes das diferentes fontes.